



Les Plus Beaux Logis de Paris

Réalisez une analyse de données **en Python**



Ouvrir le Notebook
dans Google Colab




Les Plus Beaux Logis de Paris

Partie 1 : Modèle prédictif

Évolution du marché immobilier parisien (2017-2021)

Évolution du prix moyen au m² des appartements à Paris



ÉVOLUTION 2017-2021

+ 10,1 %



ÉVOLUTION 2017-2019

+ 11,3 %



Plus de **26 000 transactions** analysées entre 2017 et 2021.



Le prix moyen au m² **augmente régulièrement** sur l'ensemble de la période.



La hausse est particulièrement marquée entre **2017 et 2019**.



La légère baisse observée en 2021 (sans doute liée au contexte sanitaire) ne remet pas en cause la **tendance haussière** du marché sur l'ensemble de la période.

Impact de la localisation et de la nature des biens

Comparaison de l'évolution du prix moyen au m²



LA LOCALISATION RESTE DÉTERMINANTE

- ✓ Les arrondissements centraux (1er, 6e, 7e, 8e) présentent **les prix les plus élevés**.
- ✓ Les arrondissements périphériques affichent des **prix plus accessibles**.
- ✓ Les **écarts de prix** entre arrondissements restent très importants.



ANALYSE DES CARACTÉRISTIQUES DES BIENS

- ✓ La **surface réelle** est fortement corrélée à la valeur foncière.
- ✓ Le **type de bien** (appartement ou local commercial) influence également le prix au m².



La localisation, le type et la surface des biens apparaissent comme **les principaux déterminants** de la valeur immobilière et serviront de base au modèle prédictif.

Construction du modèle de prédiction



OBJECTIF MÉTIER

Estimer la valeur foncière d'un bien immobilier à partir de ses caractéristiques.



VARIABLES UTILISÉES



Surface réelle



Arrondissement



Type de local



Date de transaction



MÉTHODOLOGIE


- 1 Préparation des données
- 2 Encodage des variables catégorielles (One-Hot Encoding)
- 3 Régression linéaire



SÉPARATION DES DONNÉES

- Jeu d'entraînement → 70%
- Jeu de test → 30%

DONNÉES BRUTES



Transactions immobilières
(2017 – 2021)



PRÉPARATION



Nettoyage et préparation
des données



MODÉLISATION



Régression linéaire
(apprentissage)



PRÉDICTION




Valeur foncière
prédite



Le modèle apprend les relations entre les caractéristiques des biens et leur valeur de vente.

Qualité du modèle

 Objectif : vérifier la capacité du modèle à prédire la valeur foncière



R^2

0,986

Coefficient de
détermination



< 10 %

Erreur moyenne
relative



Excellente
qualité
des prédictions



Modèle
fiable et robuste



ÉVALUATION DES PERFORMANCES

- Plus les points sont proches de la diagonale : **plus les prédictions sont précises.**
- Les écarts observés correspondent aux erreurs de prédiction.



PRÉCISION DU MODÈLE

L'algorithme fait une **erreur moyenne inférieure à 10 %**, ce qui rend les prédictions de la valeur foncière fiables.



PERTINENCE DES VARIABLES

Les résultats montrent que les variables retenues capturent l'essentiel des facteurs influant sur la valeur foncière
(excellent coefficient de détermination $R^2 = 0,986$)



Le modèle reproduit correctement les tendances générales du marché immobilier.



Résultats des prédictions sur le portefeuille d'actifs immobiliers

Au 31 décembre 2022, la valeur totale estimée du portefeuille immobilier s'élève à environ **169 M€**.
Ce portefeuille est principalement constitué d'actifs professionnels.



Accéder aux prédictions
de valorisation sur [GitHub](#)



SEGMENT PARTICULIER

- ✓ Représente **56 %** des biens du portefeuille.
- ✓ Valorisation plus dispersée mais portefeuille plus important en nombre de biens.

RÉPARTITION DU PORTEFEUILLE



SEGMENT CORPORATE

- ✓ Représente **44 %** des biens du portefeuille.
- ✓ Valeur moyenne par bien près de **1,8** fois supérieure à celle du segment particulier.

Segment	Nombre de biens	Surface totale	Valorisation totale	Valorisation moyenne
Corporate	121	7 696 m ²	97,97 M€	809 696 €
Particulier	154	6 286 m ²	71,05 M€	461 386 €



ESTIMATION STATISTIQUE BASÉE SUR LES VARIABLES DE L'HISTORIQUE 2017-2021 :



la surface
réelle



l'arrondissement



le type
de bien



la date de
transaction



LE MODÈLE NE PREND PAS EN COMPTE :



l'état
du bien



l'étage /
la présence
d'un ascenseur



les travaux
éventuels



la qualité de
l'environnement
immédiat



la vacance locative
ou le potentiel
commercial


i Ces éléments peuvent influencer la valeur réelle d'un bien et ne sont pas intégrés dans les prédictions du modèle.

Les Plus Beaux Logis de Paris

Partie 2 : Modèle de classification

Méthodologie de classification automatique

→ Retrouver les deux segments en utilisant une méthode de classification automatique du portefeuille client



Résultat de la classification



Les variables **nombre de pièces principales** et **prix au mètre carré** apparaissent comme les plus discriminantes pour distinguer les appartements des locaux commerciaux.



K-Means est particulièrement adapté à l'**exploration des données**, à la **segmentation des biens** et à l'**identification de profils d'investissement**, mais il n'a pas vocation à remplacer une information métier déjà connue.

1

Variables explicatives :

Prix au m² et nombre de pièces



Type de bien	Cluster	
	0	1
Appartement	130	24
Local industriel, commercial ou assimilé	0	121



Taux de correspondance : 91.27 %

2

Variables explicatives :

Surface réelle et prix au m²



Type de bien	Cluster	
	0	1
Appartement	138	16
Local industriel, commercial ou assimilé	88	33



Taux de correspondance : 62.2 %


LIMITES DES MODÈLES UTILISÉS

Des outils puissants, mais des interprétations à nuancer

RÉGRESSION LINÉAIRE




Prédit une valeur numérique (ex. : valeur foncière)



1. Suppose une relation linéaire

Le modèle suppose que la relation entre les variables et le prix est linéaire, ce qui est souvent simplificateur dans l'immobilier.



2. Sensible aux valeurs aberrantes

Quelques ventes exceptionnelles peuvent fortement influencer la droite de régression et dégrader les prédictions.



3. Variables importantes parfois absentes

État du bien, étage, environnement, vue, performance énergétique... autant de facteurs qui influencent le prix mais qui ne sont pas toujours disponibles.



4. Corrélation $\neq$ causalité

Une variable peut être corrélée au prix sans en être la cause (ex. : code postal).



5. Généralisation limitée dans le temps

Le modèle est appris sur les ventes passées (2017–2021) : si le marché évolue, les prédictions deviennent moins fiables.



6. Dépend fortement de la qualité des données

Erreurs de saisie, données manquantes ou incomplètes impactent directement les performances du modèle.

K-MEANS



Regroupe automatiquement des observations similaires



1. Nécessite de choisir le nombre de clusters (K)


Un mauvais choix de K peut conduire à trop de groupes ou à des groupes trop hétérogènes.



Surface (m²)	Prix au m² (€)
30	10 000
80	15 000
120	20 000

2. Sensible à la standardisation des variables et aux valeurs atypiques

Sans standardisation, les variables à grande échelle (ex. prix au m²) dominent le calcul des distances. Quelques valeurs atypiques peuvent déplacer les centres des clusters et déformer les groupes.




3. Les clusters ne sont pas des catégories métier

K-Means crée des regroupements statistiques. Rien ne garantit qu'ils correspondent à des réalités du terrain (appartement, local commercial...).



4. Résultats variables

Les clusters peuvent varier selon l'initialisation et la forme des données.



5. Fonctionne mieux pour des groupes 'ronds'

K-Means est moins adapté lorsque les groupes sont de formes complexes ou de tailles très différentes.



À RETENIR



Des outils d'aide à la décision, pas des prédictions parfaites.



Résultats à interpréter avec prudence et à confronter à l'expertise métier.



L'ajout de variables explicatives et de données plus récentes améliore la fiabilité des analyses et des prédictions.