

Optimiser la gestion & nettoyer les données du stock d'une boutique



04/2026

Contexte & objectifs

- *Données provenant d'une extraction au 31 octobre et couvrant les ventes du mois*
- *Données issues de plusieurs sources (ERP/Web/Liaison)*
- *Difficultés à analyser les données et à réaliser la gestion optimale des stocks*
- *Objectifs :*
 - *fiabiliser et rapprocher les données*
 - *analyser les performances (CA, marge, stock...)*
 - *proposer des axes d'amélioration*

Analyses exploratoires des données : 3 datasets

- *Extraction de l'ERP (825 produits, stock, prix, coûts)*
- *Extraction du site Web (ventes, descriptions)*
- *Table de liaison qui permet de lier les références entre la base de données Wordpress (Web) et l'extraction de l'ERP de l'entreprise car les identifiants sont différents entre ces deux systèmes*

Nettoyage des données ERP (1/2)

Type d'erreur	Description	Traitements réalisés
Anomalie	Le statut des stocks est incohérent avec la quantité de stock (2 lignes)	Recalcule de la colonne « stock_status » depuis « stock_quantity » en établissant une source de vérité : Si la quantité > 0 alors « instock » sinon « outofstock »
Erreur de saisie	3 prix négatifs (-20, -8, -9.1 €)	Valeur absolue appliquée
Erreur de saisie	2 stocks négatifs (-10, -1)	Valeurs ramenées à 0
Erreur de calcul	1 produit vendu sous le coût d'achat mis en évidence par le calcul de marge	Vérification manuelle et exclusion des valeurs incohérentes (Nan)

Nettoyage des données ERP (2/2)

- *Les références retenues dans le fichier ERP nettoyé correspondent à celles commercialisées sur le web soit 716 produits*

product_id	onsale_web	price	stock_quantity	stock_status	purchase_price	marge
3847	1	24.2	16	instock	12.88	11.32
3849	1	34.3	10	instock	17.54	16.76
3850	1	20.8	0	outofstock	10.64	10.16
4032	1	14.1	26	instock	6.92	7.18
4039	1	46.0	3	instock	23.77	22.23

Nettoyage des données Web (1/2)

- *L'extraction brute du site Web comprend 1513 lignes et 29 colonnes*
- *Les traitements suivant ont été réalisés :*
 - *Suppression des colonnes techniques sans « valeur métier »*

Type d'erreur	Description	Traitements réalisés
Données manquantes	85 SKU (Stock Keeping Unit) manquants	Suppression des lignes correspondantes
Doublons	798 SKU en doublons	Suppression des lignes correspondantes
Erreur de saisie	2 ventes avec des ventes négatives (-56, -17)	Lignes supprimées avec les 85 lignes sans sku
Anomalie	Certains SKU ne sont pas des valeurs numériques (« bon-cadeau-25-euros », »13127-1 »)	Les valeurs invalides, ont été isolées puis exclues du dataset afin de garantir la fiabilité des jointures

Nettoyage des données Web (2/2)

- *Le fichier Web nettoyé comprend 712 lignes et 5 colonnes*

sku	total_sales	product_type	post_title	post_type
14692	5.0	Vin	Château Fonréaud Bordeaux Blanc Le Cygne 2016	product
15328	2.0	Vin	Agnès Levet Côte Rôtie Maestria 2017	product
16515	10.0	Vin	Château Turcaud Bordeaux Rouge Cuvée Majeure 2018	product
16585	15.0	Vin	Xavier Frissant Touraine Sauvignon 2019	product
12869	7.0	Vin	Stéphane Tissot Arbois D.D. 2016	product

Nettoyage des données de la table de liaison

- *Après nettoyage la table de liaison comprend 731 lignes avec une correspondance entre les identifiants produit et web ($id_web \Leftrightarrow product_id$)*

Type d'erreur	Description	Correction
Données manquantes	91 identifiants produit ERP sans correspondance web	Suppression des lignes sans « id_web »
Anomalie	3 identifiants web non numérique	Valeurs remplacées par « NaN »

Consolidations des données (ERP, Liaison, Web)

- 1^{ère} étape consolidation (erp ↔ table de liaison) :
 - La clé « id_product » permet d'identifier chaque produit de manière unique
 - Cinq références normalement vendues sur le web ne sont pas mapées dans la table de liaison
- 2^{ème} étape consolidation (erp ↔ table de liaison) ↔ web :
 - Les clés « id_web » et « sku » permettent le rapprochement des ventes et des produits de référence de l'ERP
 - Suppression des 5 lignes sans correspondance d'identifiants
- Un dataset consolidé de 711 observations permet de tirer des enseignements fiables et exploitables pour la prise de décision

product_id	product_type	post_title	total_sales	price	purchase_price	stock_quantity	stock_status
3847	Vin	Pierre Jean Villa Saint-Joseph Préface 2018	6.0	24.2	12.88	16	instock

Recapitulatif des traitements de données

N°	Source	Type d'erreur	Description	Correction
E1	ERP	Anomalie	statut des stock incohérent avec les quantités de stock (2 lignes)	Recalcul de "stock_status" depuis "stock_quantity"
E2	ERP	Erreur de saisie	prix négatifs (-20, -8, -9.1 €)	Valeur absolue appliquée
E3	ERP	Erreur de saisie	quantité de stock négatives (-10, -1)	Valeurs ramenées à 0
E4	ERP	Erreur de calcul	produit vendu sous le coût d'achat (1)	Vérification manuelle et exclusion des valeurs incohérentes (Nan)
E5	WEB	Données manquantes	produits sans SKU (85)	Suppression des lignes correspondantes
E6	WEB	Erreur de saisie	produits avec totale des ventes négatives (-56, -17)	Lignes supprimées avec les 85 lignes sans SKU
E7	WEB	Anomalie	Identification de 2 valeurs SKU non numériques	Valeurs isolées puis exclues du dataset
E8	LIAISON	Anomalie	Identification de 3 valeurs id_web non numériques	Valeurs remplacées par NaN
E9	LIAISON	Données manquantes	91 product_id ERP sans id_web	Suppression des lignes sans id_web
E10	JOINTURE	Anomalie	Identification de 5 produits normalement vendus sur le web non mappés dans la table de liaison	A traiter
E11	JOINTURE	Données manquantes	Id sans correspondance	Filtrage des NaN

Recommandations

- **Court terme :**

- *Corriger les produits vendus sous le coût d'achat dans l'ERP*
- *Publier ou désactiver les 91 produits ERP sans équivalent web*
- *Mettre à jour le fichier de liaison avec les références des produits en stock mais non visible sur le web (product_id = 4954 et 7247)*

- **Moyen terme :**

- *Ajouter des contraintes de validation dans l'ERP (prix > 0, stock >= 0)*
- *Automatiser la synchronisation (« stock_status » ↔ « stock_quantity »)*
- *Mettre en place un processus de réconciliation mensuel WEB / ERP*


- **Long terme :**

- *Implémenter un outil de Data Visualisation connecté en temps réel*
- *Créer des alertes automatiques sur les seuils critiques*
- *Unifier les référentiels produits entre Web et ERP*

Feature Engineering

- A des fins d'analyse les variables suivantes ont été créés :
 - **'z_score'** mesure l'écart à la moyenne d'un prix en nombre d'écarts-types. Il permet d'identifier les valeurs atypiques (outliers)
 - $|Z|_{\text{score}} > 2 \rightarrow$ valeurs suspectes
 - $|Z| > 3 \rightarrow$ valeurs atypiques fortes
 - **'ca_par_article'** donne la valeur du chiffre d'affaires par article
(prix x nombre de vente)
 - **'rotation_stock'** représente le nombre de mois nécessaires pour écouler le stock actuel, au rythme des ventes observées
(quantité de stock/nombre de ventes)
 - **'stock_value'** valorise le stock (quantité de stock x prix d'achat)
 - **'taux_marge'** représente la rentabilité d'un produit
(prix HT- prix d'achat)/prix d'achat

Analyse univariée du prix



Positionnement des prix



Résultats clés :

- Prix moyen : 32 € (tirés par les valeurs atypiques élevées)
- Médiane : 23 €
- 50% des produits entre 14 € et 42 €



L'analyse par l'intervalle interquartile met en évidence 31 produits atypiques, représentant environ 4,6 % du catalogue. Ces produits présentent des prix supérieurs à 84 €. Ces valeurs reflètent la présence de produits haut de gamme dans le catalogue. La distribution des prix est asymétrique à droite, ce qui est cohérent avec un marché comprenant


- une majorité de produits standards
- et une minorité de produits premium

Analyse du chiffre d'affaire vs volume de ventes



L'analyse des top 20 en chiffre d'affaires et en quantité montre que les produits les plus vendus ne sont pas ceux qui génèrent le plus de chiffre d'affaires

Matrice CA vs volume



On distingue 4 types :



207 **produits stars**
(forts volumes + forte valeur)



149 **produits premium**
(forte valeur mais pas en volume)



180 **produits de volume**
(Top ventes mais faible CA)



174 **produits faibles**

Analyse Pareto : structure du catalogue



Constats clés :

- 60 % des produits génèrent 80 % du chiffre d'affaires total (143 204 €)
- 60 % des produits représentent 80 % des volumes de ventes
- 40 % des produits ont une faible contribution au CA ou aux ventes (présence d'une longue traîne peu performante)
- Le modèle n'est ni optimisé pour la rentabilité, ni pour la simplicité




Les ventes reposent sur un double moteur : des produits qui génèrent de la valeur, et des produits de volume qui génèrent du flux. L'enjeu est d'optimiser cet équilibre en :

- Développant les produits premium/stars
- Gardant les produits volume
- Réduisant ou supprimant les moins performants

Analyse du stock

Flop 20 des produits avec le plus de mois de stock



👉 Constats clés

- *Surstock massif sur certains produits (14 à 31 mois de stock)*
- *Valeur totale du stock (prix d'achat) : 269 241 € (>CA)*
- *Quantité totale de produits en stock : 16 678 (alors que certains produits sont en rupture)*


👉 *Une partie significative du stock est immobilisée sur des produits à faible rotation, générant un coût financier et un risque business*

👉 *Piloter le stock par la demande réelle en mettant en place des seuils max et alertes sur surstock*


Analyse du taux de marge

- 👉 **Constat clé :** La rentabilité est principalement portée par les spiritueux
- Prioriser les produits à forte marge (Cognac / Whisky / Gin)
 - Repenser le rôle du champagne qui présente une marge limitée bien que produit premium (pricing, marketing)
 - Arbitrer les produits peu rentables

Taux de marge moyen (%) par type de produit



Analyse des corrélations : stock, sales et price



Constats clés :

- Plus le prix est élevé, moins le produit se vend (produits premium → faibles volumes vs produits accessibles → volumes élevés)
- Le stock élevé entraîne directement une immobilisation financière
- La marge n'est pas pilotée (aucune corrélation avec les ventes ou le CA)
- Le chiffre d'affaires est tiré par le prix, mais la rentabilité et le stock ne sont pas alignés avec la performance commerciale

Axes d'amélioration prioritaires « data-driven »

AXE 1 — Recentrer le catalogue sur les produits créateurs de valeur

- Identifier les produits : faible CA, faible volume, faible marge
- Déréférencer ou réduire leur présence
- Concentrer les efforts sur les produits performants

 **Simplification du catalogue, meilleure lisibilité commerciale, gain de rentabilité**

AXE 2 — Piloter la rentabilité (marge) et revoir le pricing

- Définir un seuil minimum de marge
- Segmenter les produits

 **Augmentation du résultat sans augmenter le volume, meilleur mix produit**

AXE 3 — Optimiser les stocks et réduire les surstocks

- Fixer des seuils de stock (2 à 4 mois max)
- Réduire les stocks sur produits lents
- Prioriser les produits à forte rotation et produits à fort CA
- Mettre en place des alertes (surstock/rupture)

 **Réduction du cash immobilisé, amélioration de la rotation, baisse des ruptures critiques**